

Лабораторна робота 5 – Штучні нейронні мережі.

Завдання 1. Розв'яжіть лабораторну №3 за допомогою нейронної мережі. Кількість шарів, нейронів, метод оптимізації – на Ваш розсуд. Дозволяється використання обгортки Keras для побудови моделі, однак реалізація на чистому TensorFlow (або PyTorch) заохочується додатковими балами.

Завдання було виконано за допомогою TensorFlow та Keras.

Код класу LogisticRegression з використанням чистого TensorFlow:

```
24 class LogisticRegression(tf.Module):
25     def __init__(self, x):
26         self.mean = tf.Variable(tf.math.reduce_mean(x, axis=0))
27         self.std = tf.Variable(tf.math.reduce_std(x, axis=0)) + pow(10, -8)
28     def normalize(self, x):
29         return (x - self.mean)/self.std
30     def GetTrainAndTestDataSets(self, BatchSize, x_train, y_train, x_test, y_test):
31         TrainDataset = tf.data.Dataset.from_tensor_slices((x_train, y_train))
32         TrainDataset = TrainDataset.shuffle(buffer_size=x_train.shape[0]).batch(BatchSize)
33         TestDataset = tf.data.Dataset.from_tensor_slices((x_test, y_test))
34         TestDataset = TestDataset.shuffle(buffer_size=x_test.shape[0]).batch(BatchSize)
35         return TrainDataset, TestDataset
36     def ComputeTheModelOutput(self, x, w, b):
37         return tf.nn.softmax(tf.add(tf.matmul(x, w), b))
38     def GetAccuracy(self, y_pred, y):
39         prediction = tf.equal(tf.argmax(y_pred, 1), tf.argmax(y, 1))
40         return tf.reduce_mean(tf.cast(prediction, tf.float32))
41     def GetLoss(self, y_pred, y):
42         return tf.nn.softmax_cross_entropy_with_logits(labels=y, logits=y_pred)
43     def RunModel(self, CountOfEpochs, LearningRate, TrainDataset, TestDataset,
44                 DetailedOutputOn):
45         w, b = tf.Variable(tf.zeros([784,10])), tf.Variable(tf.zeros([10]))
46
47         for epoch in range(CountOfEpochs):
48             BatchTrainLosses, BatchTrainAccuracies = [], []
49             BatchTestLosses, BatchTestAccuracies = [], []
50             for XBatch, YBatch in TrainDataset:
51                 with tf.GradientTape() as tape:
52                     YPredBatch = self.ComputeTheModelOutput(XBatch, w, b)
53                     BatchLoss = self.GetLoss(YPredBatch, YBatch)
54                     BatchAccuracy = self.GetAccuracy(YPredBatch, YBatch)
55                     gradients = tape.gradient(BatchLoss, [w, b])
56                     for g, v in zip(gradients, [w, b]):
57                         v.assign_sub(LearningRate * g)
58                     BatchTrainLosses.append(BatchLoss)
59                     BatchTrainAccuracies.append(BatchAccuracy)
60             gradients=[]
61             tape=[]
62             for XBatch, YBatch in TestDataset:
63                 YPredBatch = self.ComputeTheModelOutput(XBatch, w, b)
64                 BatchLoss = self.GetLoss(YPredBatch, YBatch)
65                 BatchAccuracy = self.GetAccuracy(YPredBatch, YBatch)
66             BatchTestLosses.append(BatchLoss)
67             BatchTestAccuracies.append(BatchAccuracy)
68             TrainLoss, TrainAccuracy = tf.reduce_mean(BatchTrainLosses), tf.reduce_mean(
69                 BatchTrainAccuracies)
70             TestLoss, TestAccuracy = tf.reduce_mean(BatchTestLosses), tf.reduce_mean(
71                 BatchTestAccuracies)
72         return TrainAccuracy, TestAccuracy, TrainLoss, TestLoss
```

Опис проведених досліджень

Реалізація логістичної регресії за допомогою TensorFlow для вирішення задач багатокласової та бінарної класифікації дещо відрізняється: для обчислення функції активації та коефіцієнта втрат використовувався інструмент softmax замість sigmoid.

На відміну від попередньої роботи, ми аналізували як точність, так і значення втрат на тренувальних та тестових даних, а також кількість навчальних епох, проте вплив поліноміальності та коефіцієнтів α_1 і α_2 не досліджувались.

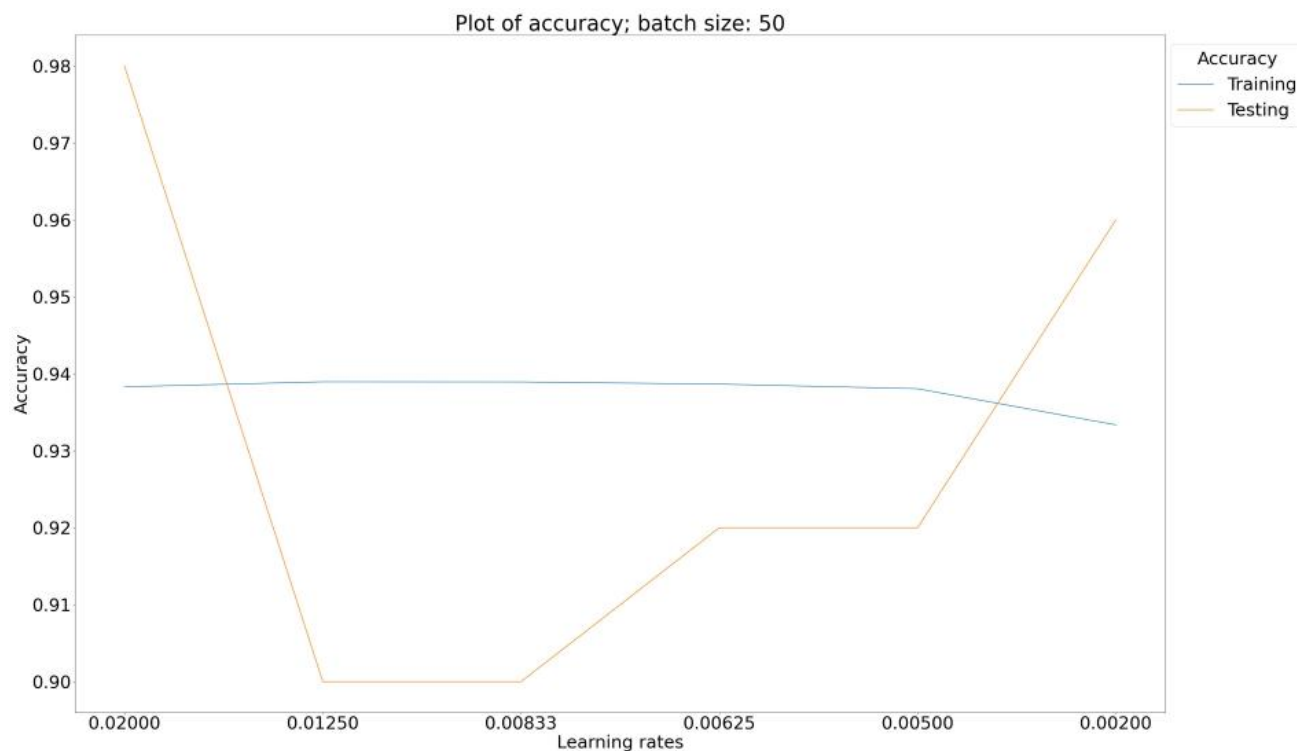
Запустивши код із стандартними параметрами, ми отримали наступний вивід:

```
Count of epochs: 10 ; batch size: 32 ; learning rate: 0.00100...  
Training accuracy.: 0.92805 ; testing accuracy.: 0.93750;  
Training loss: 1.54361 ; testing loss: 1.52456; time: 0 : 1 : 17
```

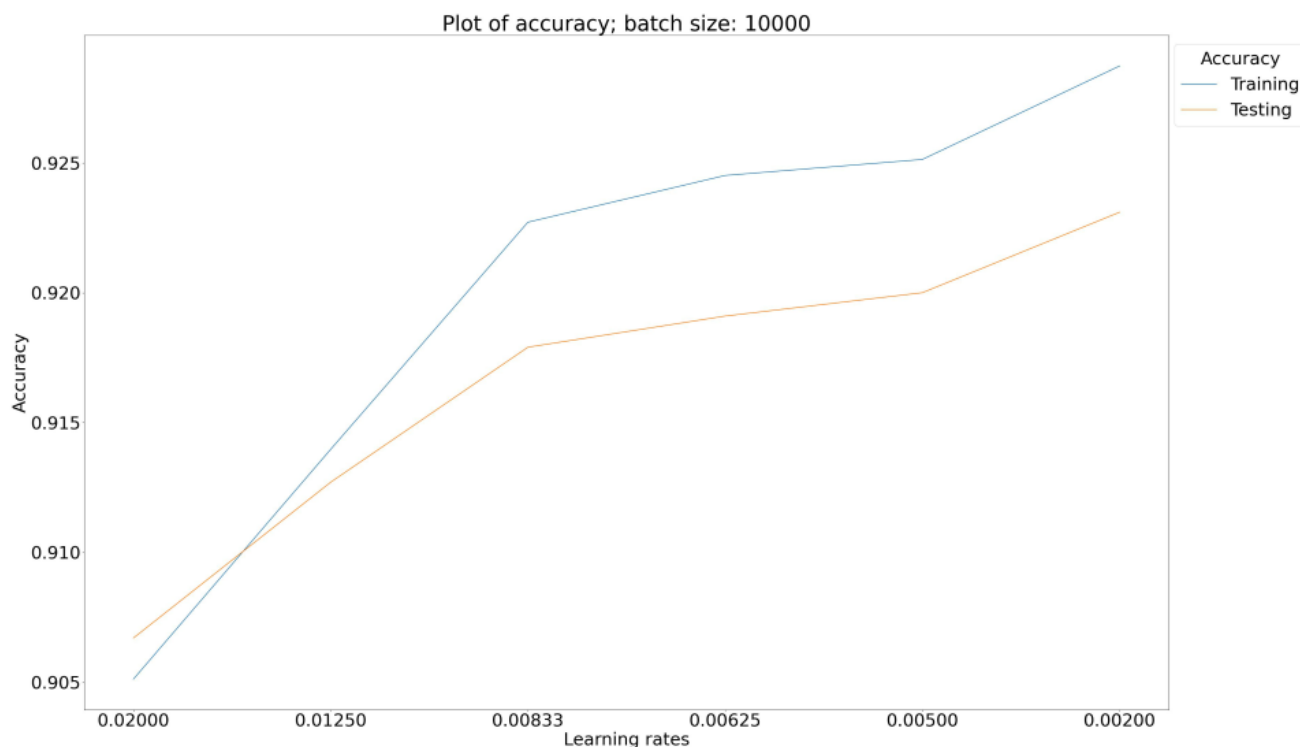
Видно, що точність нашої моделі на тестових даних, реалізованої за допомогою TensorFlow, виявилась більшою на 6.56%.

Як і в попередніх роботах, з ціллю оптимізації ми винесли деякі підготовчі дії в окремий метод, який виконується перед початком нової серії експериментів з іншим розміром частини вибірки (BatchSize). Програма також містить код для визначення часових витрат, фіксації результатів у вигляді графіків, діаграм різних типів та текстового csv-файлу, який при необхідності може бути проаналізований табличним процесором.

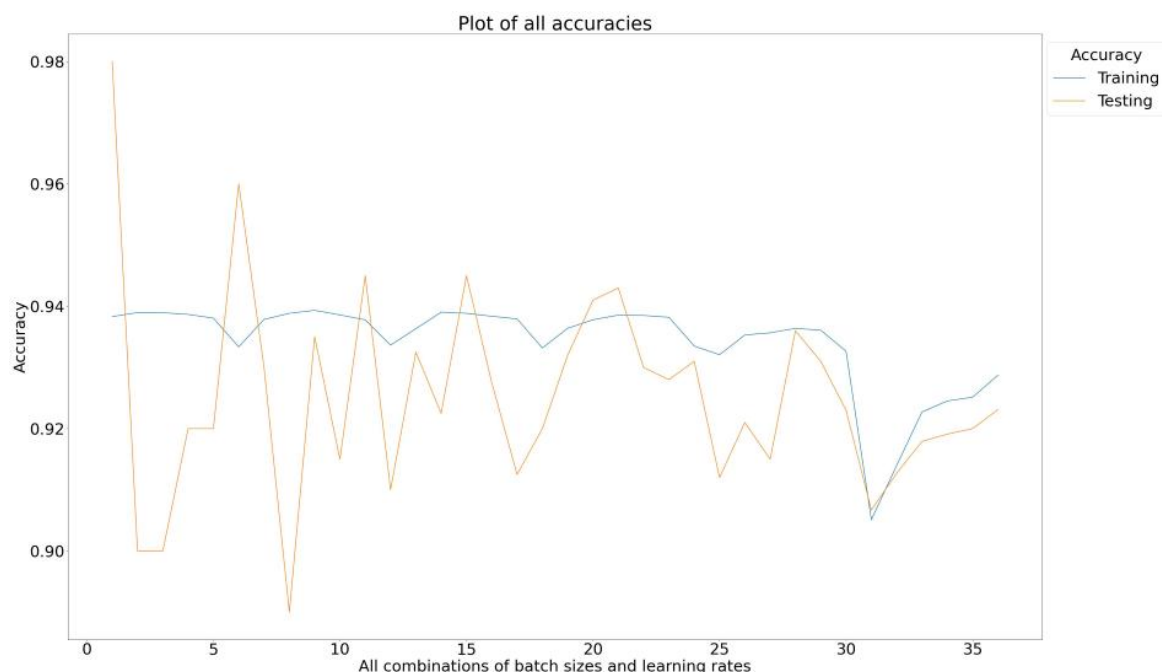
Тестування моделі включало в себе перебір різних розмірів частини вибірки (BatchSize) з коефіцієнтами швидкості навчання (LearningRate), а кількість епох при цьому була 10. Після визначення найкращих значень цих параметрів було виконано один експеримент із кількістю епох 1000. Наведемо графік, який ілюструє зміну точності при певному BatchSize з різними значеннями LearningRate:



Коефіцієнт швидкості навчання достатньо сильно впливає на якість моделі, проаналізованої на тестових даних, та менше впливає на точність при аналізі тренувальної вибірки. Схожу історію помітно при інших BatchSize окрім 10000:




Тут ми бачимо правильну тенденцію, коли зростання коефіцієнта швидкості навчання призводить до збільшення точності моделі на всіх двох типах даних, причому рівень якості на тестовій вибірці у переважній більшості випадків нижчий за тренувальний. Графіки функції втрат є повністю оберненими до наданих. Проілюструємо глобальну зміну якості моделі при всіх комбінаціях описаних параметрів на тренувальних та тестових даних:




Видно, що точність, отримана на тренувальній вибірці, є більш стабільною.

Наведемо графік зміни якості моделі на кожній з епох:



Ми бачимо подібну тенденцію: точність на тренувальній вибірці є набагато стабільнішою за точність на тестовій вибірці, і в більшості випадків вона є вищою.

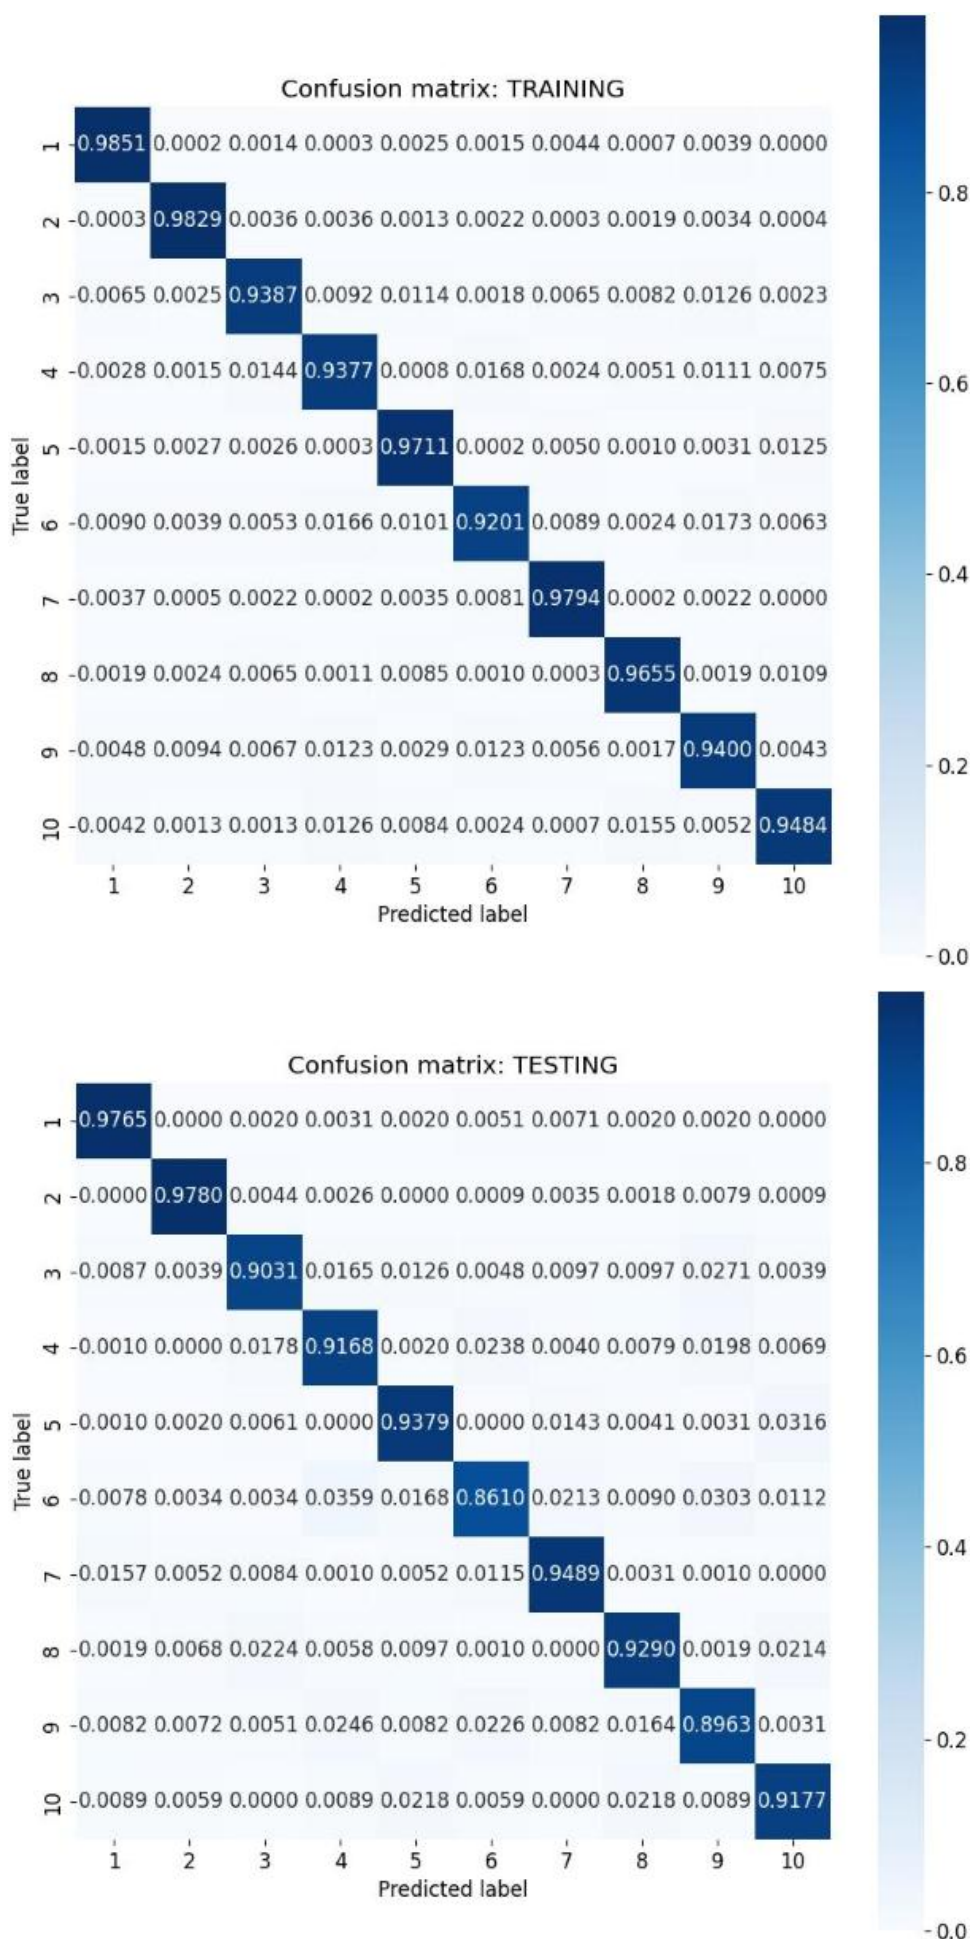
Такі ж результати показують і кольорові діаграми:



Після завершення всіх випробувань був отриманий наступний вивід на екран:

```
Epoch 998 / 1000... Training accuracy.: 0.95752 ; testing accuracy.: 0.94000
Training loss: 1.50404 ; testing loss: 1.52290;
-----
Epoch 999 / 1000... Training accuracy.: 0.95752 ; testing accuracy.: 0.95000
Training loss: 1.50404 ; testing loss: 1.51187;
-----
Epoch 1000 / 1000... Training accuracy.: 0.95752 ; testing accuracy.: 0.93000
Training loss: 1.50403 ; testing loss: 1.53117;
-----
Training accuracy.: 0.95752 ; testing accuracy.: 0.93000;
Training loss: 1.50403 ; testing loss: 1.53117; time: 0 : 25 : 43
Total time of all calculations: 0 : 33 : 51
Building plots... Time: 0 : 0 : 7
```

Для кращої моделі були побудовані діаграми типу «Confusion matrix»:



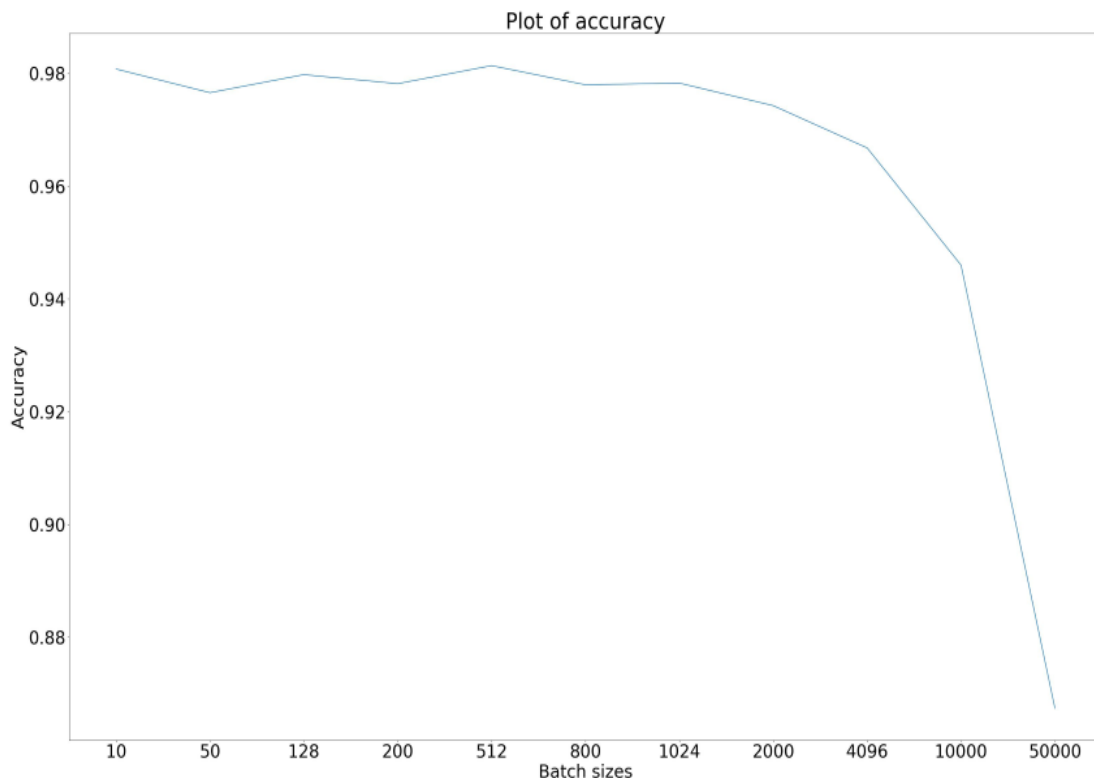
Завдання даної лабораторної роботи також було виконано за допомогою Keras:

```
31 def KerasLogisticRegression(x_train, y_train, x_test, y_test, CountOfEpochs, BatchSize,
    DetailedOutputOn):
32     model = Sequential()
33     model.add(Dense(512, input_dim=28 * 28, activation='relu', name='Hidden-1'))
34     model.add(Dense(256, activation='relu', name='Hidden-2'))
35     model.add(Dense(10, activation='softmax', name='Output'))
36     model.compile('adam', loss='categorical_crossentropy', metrics=['accuracy'])
37     history = model.fit(x_train, y_train, epochs=CountOfEpochs, batch_size=BatchSize,
        validation_split=0.2, verbose=0)
38     AccuracyAndLoss = model.evaluate(x=x_test, y=y_test, verbose=0)
39     if DetailedOutputOn:
40         train_pred = model.predict(x_train, verbose=0)
41         test_pred = model.predict(x_test, verbose=0)
42         return AccuracyAndLoss[1], AccuracyAndLoss[0], history, train_pred, test_pred
43     return AccuracyAndLoss[1], AccuracyAndLoss[0]
```


Ми бачимо, що модель, створена за допомогою Keras, майже на 5% точніша, ніж TensorFlow з параметрами, як у попередніх двох роботах:

```
Count of epochs: 10 ; batch size: 32... Time: 0 : 1 : 34
Accuracy: 0.97560 ; loss: 0.12142
```

Оскільки обраний метод оптимізації («adam») автоматично задає значення параметра LearningRate (коефіцієнт швидкості навчання) в залежності від отриманого градієнта, ми його не аналізували, хоча в Keras, можливо, є способи змінити його. Тому ми перевіряли вплив BatchSize (розмір частини вибірки) на точність та коефіцієнт втрат лише на тестових даних, з кількістю епох 10:

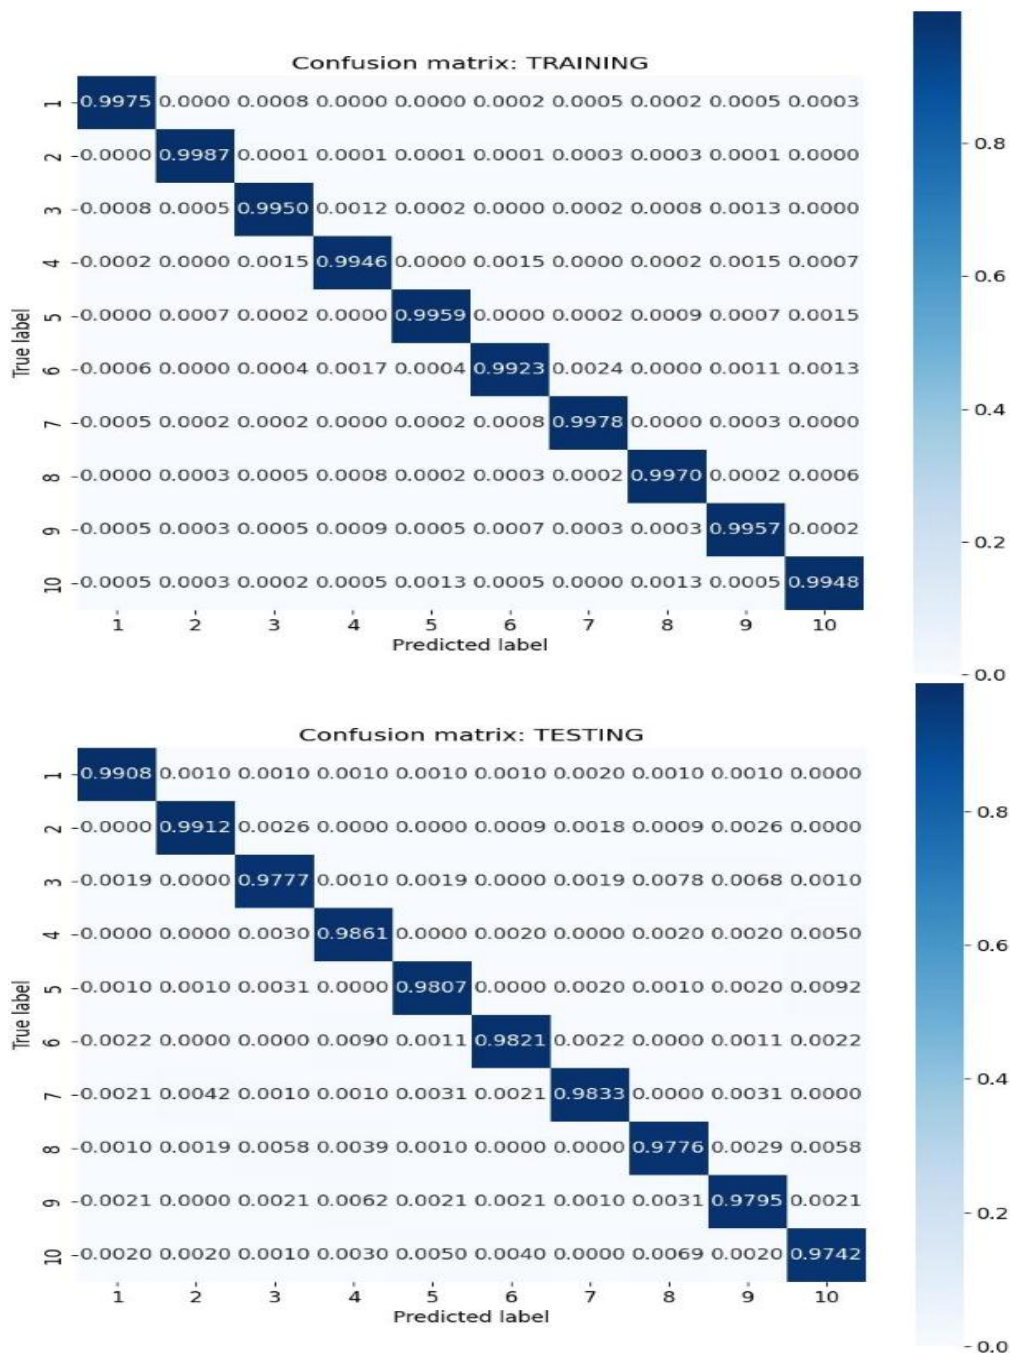


Видно, що розмір частини вибірки, більший за 2000, призводить до стрімкого погіршення якості моделі. Після отримання найкращого значення (512) було виконано один експеримент з кількістю епох 1000, отримано такі графіки:



Можна помітити, що загальний рівень точності на тестових даних у переважній більшості випадків вищий, ніж на валідаційних.

Для кращої моделі були побудовані діаграми типу «Confusion matrix»:



Оскільки попереднє рішення має ряд недоліків, ми створили ще одне, з більшою кількістю шарів Keras, а також з можливістю аналізувати LearningRate:

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import matplotlib.ticker as ticker
4 from sklearn.metrics import confusion_matrix
5 import random
6 from sklearn.utils import shuffle
7 import os
8 os.environ['TF_CPP_MIN_LOG_LEVEL'] = '1'
9 os.environ['CUDA_VISIBLE_DEVICES'] = '-1'
10 import tensorflow as tf
11 import tensorflow_datasets as tfds
12 from sklearn.preprocessing import OneHotEncoder
13 from datetime import datetime
14 from datetime import timedelta
15 def preprocess(dataset):
16     image = tf.cast(dataset['image'], dtype=tf.float32) / 255.
17     label = tf.cast(dataset['label'], dtype=tf.float32)
18     return image, label
19 def SimpleConvolutionalNeuralNetworkModel(NumberOfClasses):
20     input_ = tf.keras.layers.Input(shape=(28, 28, 1))
21     x = tf.keras.layers.Conv2D(64, (3, 3), padding='same', activation='relu')(input_)
22     x = tf.keras.layers.MaxPool2D(2, 2)(x)
23     x = tf.keras.layers.Dropout(0.5)(x)
24     x = tf.keras.layers.Conv2D(32, (3, 3), padding='same', activation='relu')(x)
25     x = tf.keras.layers.MaxPool2D(2, 2)(x)
26     x = tf.keras.layers.Dropout(0.5)(x)
27     x = tf.keras.layers.Conv2D(16, (3, 3), padding='same', activation='relu')(x)
28     x = tf.keras.layers.MaxPool2D(2, 2)(x)
29     x = tf.keras.layers.Dropout(0.5)(x)
30     x = tf.keras.layers.Flatten()(x)
31     x = tf.keras.layers.Dense(128, activation='relu')(x)
32     output_ = tf.keras.layers.Dense(NumberOfClasses, activation='softmax')(x)
33     return tf.keras.models.Model(input_, output_, name='Classifier')
34 def RunLogisticRegression(CountOfEpochs, BatchSize, LearningRate, TrainData, ValidationData,
35     TestData, MetaData):
36     TrainData = TrainData.map(preprocess).shuffle(buffer_size=1024).batch(BatchSize)
37     ValidationData = ValidationData.map(preprocess).batch(BatchSize)
38     TestData = TestData.map(preprocess).batch(BatchSize)
39     NumberOfClasses = MetaData.features['label'].num_classes
40     model = SimpleConvolutionalNeuralNetworkModel(NumberOfClasses)
41     lr_schedule = tf.keras.optimizers.schedules.ExponentialDecay(LearningRate, decay_steps=
42         100000, decay_rate=0.96)
43     model.compile(optimizer = tf.keras.optimizers.Adam(learning_rate=lr_schedule), loss = tf.
44         keras.losses.SparseCategoricalCrossentropy(), metrics = ['accuracy'])
45     history = model.fit(TrainData, epochs=CountOfEpochs, validation_data=ValidationData,
46         verbose=0)
47 if(CountOfEpochs>1):
48     fig,ax=plt.subplots(ncols=2, figsize=(20, 6))
49     ax[0].set_title('Accuracy and validation accuracy')
50     ax[0].set_xlabel('Epoch')
51     ax[0].set_ylabel('Accuracy')
52     ax[0].plot([i+1 for i in range(CountOfEpochs)],history.history['accuracy'], label =
53         'Train accuracy')
54     ax[0].plot([i+1 for i in range(CountOfEpochs)],history.history['val_accuracy'], label =
55         'Validation accuracy')
56     ax[0].legend(bbox_to_anchor = (0.0005,1.13),loc = 'upper right', title="Accuracy",
57         labels=['Accuracy','Valid. accuracy'],fontsize=14)
58     ax[1].set_title('Loss and validation loss')
59     ax[1].set_xlabel('Epoch')
60     ax[1].set_ylabel('Accuracy')
61     ax[1].plot([i+1 for i in range(CountOfEpochs)],history.history['loss'], label =
62         'Train loss')
63     ax[1].plot([i+1 for i in range(CountOfEpochs)],history.history['val_loss'], label =
64         'Validation loss')
65     ax[1].legend(bbox_to_anchor = (1.263,1.13),loc = 'upper right', title="Loss",labels=[
66         'Loss','Valid. loss'],fontsize=14)
67     plt.savefig("Plots\\CountOfEpochs "+str(CountOfEpochs)+" BatchSize "+str(BatchSize)+
68         " LearningRate "+f'{LearningRate:.5f}'+".jpg",dpi=200)
69     plt.close()
70 return model
```

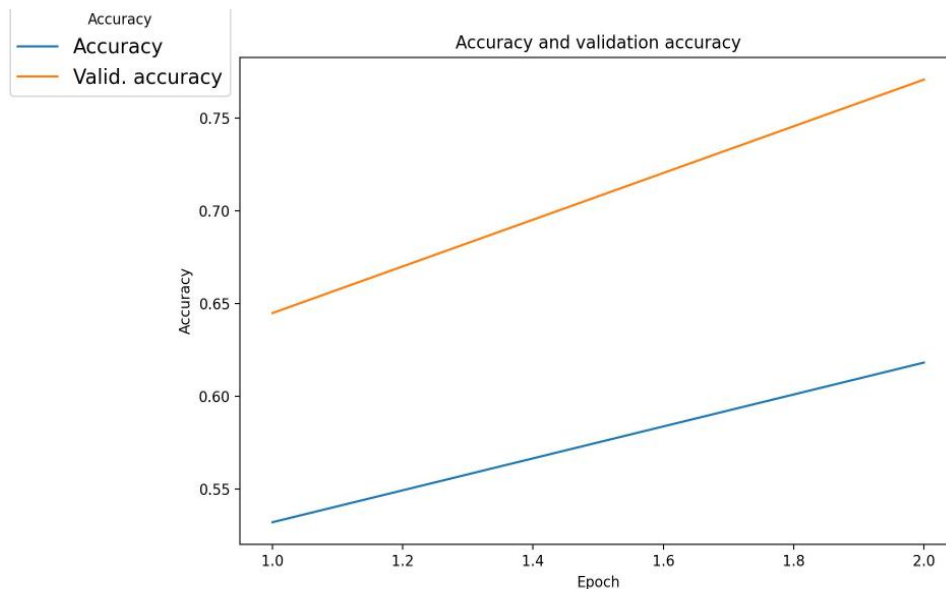

Запустивши код із стандартними параметрами, ми отримали наступний вивід:

```
Count of epochs: 10 ; batch size: 32 ; learning rate: 0.00100  
Processing... Time: 0 : 7 : 37 ; accuracy: 0.98456
```


Бачимо, що точність даної моделі більша за попередню лише на майже 1%, проте обчислення тривали в рази довше з тими самими параметрами.

Нами було проведено багато експериментів з усіма комбінаціями кількості епох (від 1 до 5), розмірів частини вибірки (BatchSize) та коефіцієнтів швидкості навчання (LearningRate), для кожної з них було побудовано графіки такого вигляду:

CountOfEpochs 2 BatchSize 32 LearningRate 0.02000

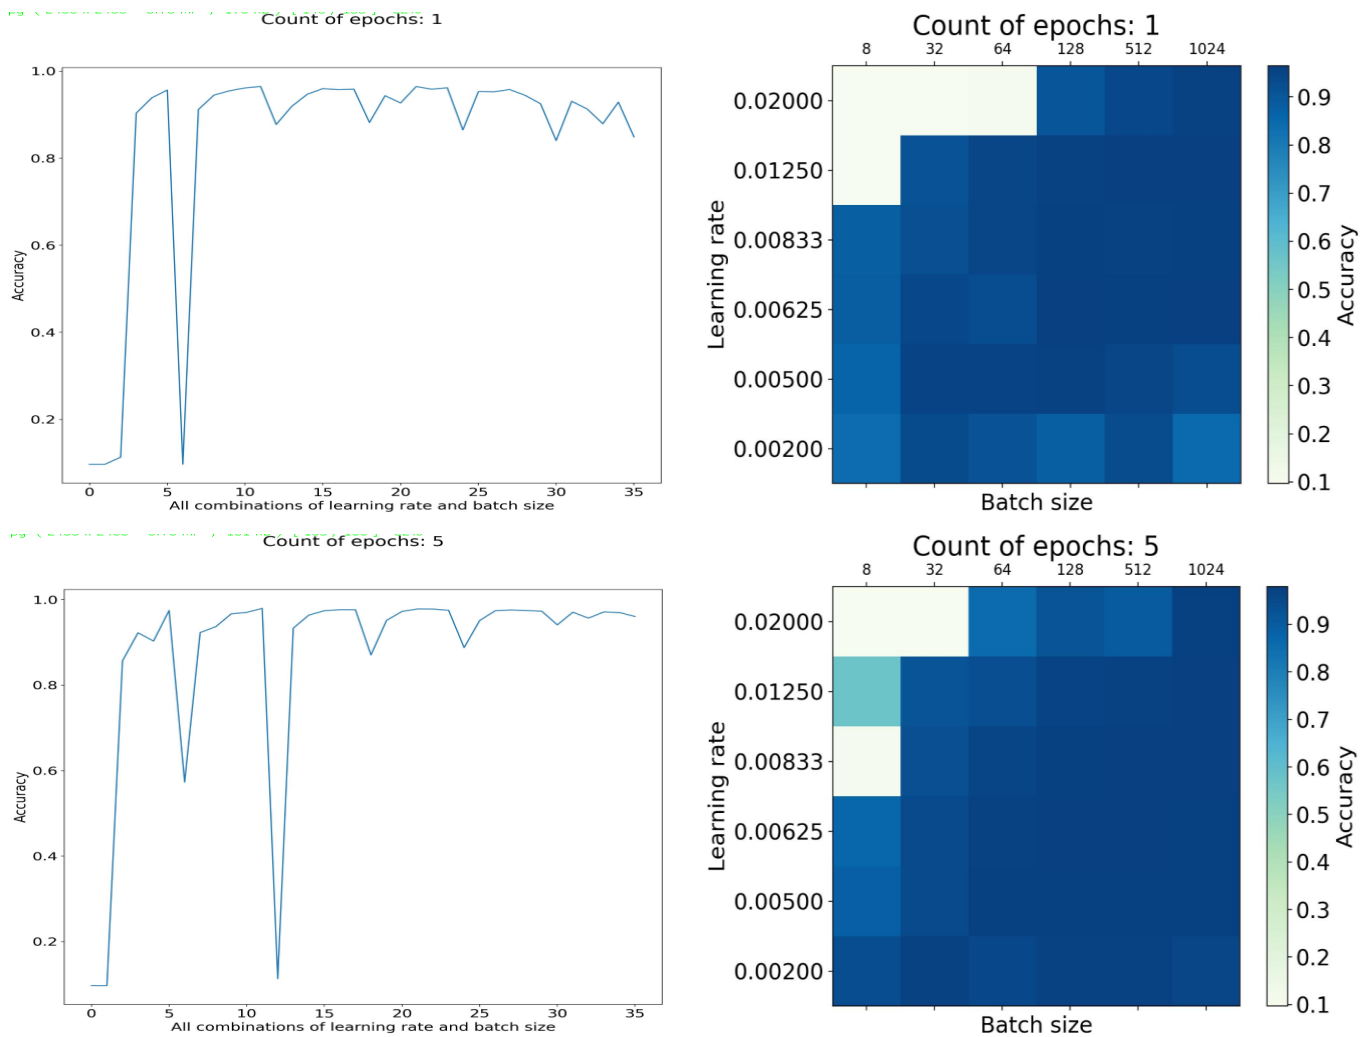


CountOfEpochs 5 BatchSize 32 LearningRate 0.02000



Видно, що зі збільшенням кількості навчальних епох загальний рівень точності роботи моделі на валідаційних та тестових даних збільшується, а у переважній більшості випадків валідаційна точність вища за тестову.

Для кожної епохи також отримали більш загальні графіки та діаграми:



Підсумковий графік та кольорова діаграма виглядають таким чином:

