**НАЦІОНАЛЬНИЙ ТЕХНІЧНИЙ УНІВЕРСИТЕТ УКРАЇНИ «КИЇВСЬКИЙ ПОЛІТЕХНІЧНИЙ ІНСТИТУТ ІМЕНІ ІГОРЯ СІКОРСЬКОГО»**

**Факультет інформатики та обчислювальної техніки**

**Кафедра інформатики та програмної інженерії**

**Комп'ютерний практикум № 1**

з дисципліни «**Оброблення надвеликих масивів даних**»

Тема: «Робота з графовими структурами»

Виконав:
студент групи ІП-з41мп
Дишкант Лариса Леонідівна

Перевірив:
к.т.н. доцент кафедри ІПІ
Олійник Ю.О.

Київ 2024

**Завдання**

1.Використовуючи Spark Graphx / GraphFrame та дані про авіасполучення вирішити, описаний нижче ряд задач.

2.Використати дані:

- airports-extended.dat;
- airlines.dat;
- routes.dat;
- опис даних - https://openflights.org/data.html

3.Вирішити наступні задачі

- Знайти авіакомпанію з найбільшою сумою відстаней всіх рейсів. Теж саме з найменшою сумою.
- Знайти всі можливі рейси між Польщею та Бельгією (при не більше ніж 2-х стиковках). Використайте motif та інші варіанти рішень, порівняйте їх результати по швидкодії та складності реалізації.
- Знайти аеропорти з найменшою та найбільшою кількістю рейсів.
- Знайти найкоротший та найдовший маршрут між 2 заданими аеропортами. За довжину рейсу беремо відстань між аеропортами. Необхідно врахувати маршрути з пересадками (не більше 4).
- Знайти авіакомпанію з найбільшою сумою відстаней всіх рейсів.
- Виділити великі кластери аеропортів (не менше 5, на основі інформації про рейси). Проаналізувати результати створення цих кластерів.
- Знайти підграфи, з кількістю вузлів не менше 2 зв’язаних між собою, які не мають зв’язків з іншими аеропортами.

**1.Знайти авіакомпанію з найбільшою сумою відстаней всіх рейсів. Теж саме з найменшою сумою**

Перед виконанням завдання потрібно авторизуватися на https://community.cloud.databricks.com/ створити ноутбук та в UI Spark завантажити бібліотеку для роботи з графами graphframes:graphframes:0.8.2-spark3.1-s_2.12.

Наступним кроком потрібно імпортувати відповідні модулі та компоненти для роботи і завантажити дані перед чим створити схеми відповідно даних (рисунок 1 - рисунок 3).

```
10:19 PM (2s)                                                    2

from pyspark.sql import SparkSession
import pyspark.sql.types as T
from pyspark.sql.functions import col, udf
from math import radians, cos, sin, asin, sqrt
from graphframes import GraphFrame

spark = SparkSession.builder \
    .appName("Graphs") \
    .getOrCreate()

# Схема для файлів
schema_airports = T.StructType([
    T.StructField("AirportID", T.StringType(), True),
    T.StructField("Name", T.StringType(), True),
    T.StructField("City", T.StringType(), True),
    T.StructField("Country", T.StringType(), True),
    T.StructField("IATA", T.StringType(), True),
    T.StructField("ICAO", T.StringType(), True),
    T.StructField("Latitude", T.DoubleType(), True),
    T.StructField("Longitude", T.DoubleType(), True),
    T.StructField("Altitude", T.IntegerType(), True),
    T.StructField("Timezone", T.StringType(), True),
    T.StructField("DST", T.StringType(), True),
    T.StructField("Tz_database_time_zone", T.StringType(), True),
    T.StructField("Type", T.StringType(), True),
```

Рисунок 1 - Створення схеми даних

```
# Завантаження даних
airports_df = spark.read.csv("dbfs:/FileStore/shared_uploads/dyshkant.
larisa.2@gmail.com/airports_extended.dat", schema=schema_airports,
header=False)
routes_df = spark.read.csv("dbfs:/FileStore/shared_uploads/dyshkant.
larisa.2@gmail.com/routes.dat", schema=schema_routes, header=False)
```

Рисунок 2 - Завантаження даних

```
airports_df: pyspark.sql.dataframe.DataFrame
    AirportID: string
    Name: string
    City: string
    Country: string
    IATA: string
    ICAO: string
    Latitude: double
    Longitude: double
    Altitude: integer
    Timezone: string
    DST: string
    Tz_database_time_zone: string
    Type: string
    Source: string
routes_df: pyspark.sql.dataframe.DataFrame
    Airline: string
    AirlineID: string
    SourceAirport: string
    SourceAirportID: string
    DestinationAirport: string
    DestinationAirportID: string
    Codeshare: string
    Stops: integer
    Equipment: string
```

Рисунок 3 - Результат

Для знаходження авіакомпанії з найбільшою та найменшою сумою відстані всіх рейсів, потрібно відповідно для початку розрахувати відстані між двома точками. І для даної операції створимо функцію, яка буде за це відповідати. Щоб переглянути результат роботи функції виведемо його, створивши датафрейм, який складається з колонок: Аеропорт, id початкового аеропорта, id кінцевого аеропорта та дистанції між ними (рисунок 4).

```
routes_with_distance: pyspark.sql.dataframe.DataFrame
        Airline: string
        src: string
        dst: string
        Distance: double

+-------+----+----+------------------+
|Airline| src| dst|          Distance|
+-------+----+----+------------------+
|     2B|2965|2990| 1505.879588577336|
|     2B|2966|2990| 1039.785085850871|
|     2B|2966|2962| 447.8835306472578|
|     2B|2968|2990| 770.0247403003692|
|     2B|2968|4078| 1337.791013617074|
|     2B|4029|2990| 715.2000336731971|
|     2B|4029|6969| 891.8225097523026|
|     2B|4029|6160| 950.8348464083632|
|     2B|6156|2952|1171.1457354374106|
|     2B|6156|2990|1007.6200834940136|
|     2B|2922|6969|1684.3683378867422|
|     2B|2952|6156|1171.1457354374106|
|     2B|2990|2965| 1505.879588577336|
|     2B|2990|2966| 1039.785085850871|
|     2B|2990|2968| 770.0247403003692|
|     2B|2990|4029| 715.2000336731971|
|     2B|2990|6156|1007.6200834940136|
```

Рисунок 4 - Результат роботи функції, яка визначає дистанцію

Використав агреговану функцію знаходимо суми відстаней та виводимо найбільшу та найменшу (рисунок 5).

```
Авіакомпанія з найбільшою сумою відстаней: AA з 5430366.439486928 км
Авіакомпанія з найменшою сумою відстаней: Q3 з 38.13677928959219 км
```

Рисунок 5 - Результат виконання 1 завдання для знаходження авіакомпанії з найбільшою сумою відстаней та найменшою

**2.Знайти всі можливі рейси між Польщею та Бельгією (при не більше ніж 2-х стиковках). Використайте motif та інші варіанти рішень, порівняйте їх результати по швидкодії та складності реалізації**

Використаємо **motif** для виконання завдання та виконаємо в різних ячейках, щоб можна було порівняти виконання двох методів знаходження всіх можливих рейсів між Польщею та Бельгією. Виведемо результати варіантів з однією, з двома та прямих рейсів (рисунок 6).

```
Кількість маршрутів між Польшею і Бельгією з двома стиковками - 208260 з однією стиковкою -  588, прямі рейси - 6
+--------------------+--------------------+--------------------+
|                   a|                  e1|                   b|
+--------------------+--------------------+--------------------+
|{669, John Paul I...|{669, 304, FR, 10...|{304, Brussels So...|
|{8414, Modlin Air...|{8414, 304, FR, 1...|{304, Brussels So...|
|{668, Gdańsk Lech...|{668, 302, K2, 10...|{302, Brussels Ai...|
|{680, Copernicus ...|{680, 302, K2, 86...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 302, LO, 11...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 304, W6, 11...|{304, Brussels So...|
+--------------------+--------------------+--------------------+

+--------------------+--------------------+--------------------+--------------------+--------------------+
|                   a|                  e1|                   b|                  e2|                   c|
+--------------------+--------------------+--------------------+--------------------+--------------------+
|{679, Warsaw Chop...|{679, 3959, LO, 3...|{3959, Vilnius In...|{3959, 302, SN, 1...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 3959, LO, 3...|{3959, Vilnius In...|{3959, 302, LT, 1...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 3959, LO, 3...|{3959, Vilnius In...|{3959, 302, LH, 1...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 3959, LO, 3...|{3959, Vilnius In...|{3959, 304, FR, 1...|{304, Brussels So...|
|{679, Warsaw Chop...|{679, 3959, LO, 3...|{3959, Vilnius In...|{3959, 302, BT, 1...|{302, Brussels Ai...|
```

Рисунок 6 - Результат виконання 2 завдання використовуючи motif

Для методу BFS результат виконання на рисунку 7.

```
all_paths: pyspark.sql.dataframe.DataFrame = [from: struct, e0: struct ... 1 more field]
+--------------------+--------------------+--------------------+
|                from|                  e0|                  to|
+--------------------+--------------------+--------------------+
|{669, John Paul I...|{669, 304, FR, 10...|{304, Brussels So...|
|{8414, Modlin Air...|{8414, 304, FR, 1...|{304, Brussels So...|
|{668, Gdańsk Lech...|{668, 302, K2, 10...|{302, Brussels Ai...|
|{680, Copernicus ...|{680, 302, K2, 86...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 302, LO, 11...|{302, Brussels Ai...|
|{679, Warsaw Chop...|{679, 304, W6, 11...|{304, Brussels So...|
+--------------------+--------------------+--------------------+
```

Рисунок 7 - Результат виконання завдання 2 використовуючи метод BFS

Якщо порівнювати два методи то можна сказати, що вони досить швидко справилися з завданням. motif - 13 сек, але з візуалізацією всіх варіантів які можливі, тобто і з двома, якщо візуалізовувати тільки з одним то виконання займає 9 сек. А метод BFS взагалі виводить найкоротші та час виконання задачі зайняв всього 4 сек. Тому однозначно відповісти який метод швидше відпрацьовує можна сказали лише тоді якщо вони працюватимуть над однією задачою. Але одне точно, що motif справився з усіма поставленими завданнями чітко на відміну BFS знаходить найкоротший шлях та виводить тільки його. Сам метод і відповідає за визначення найкоротшого шляху, тому з завданням теж справляється.

**3.Знайти аеропорти з найменшою та найбільшою кількістю рейсів.**

Для виконання ми знайдемо ступінь вершин та об’єднаємо з фреймом аеропортів. Використовуючи агреговані функції знайдемо максимальну кількість та мінімальну рейсів, відфільтруємо та  візуалізуємо (рисунок 8 та рисунок 9). В результаті отримали, що з максимальною кількістю рейсів - 1 аеропорт і ця кількість - 1826, а з мінімальною кількістю 22 аеропортів з мінімальною кількістю в 1рейс.

```
+----+--------------------+------+
|  id|                name|degree|
+----+--------------------+------+
|3682|Hartsfield Jackso...|  1826|
+----+--------------------+------+

+----+--------------------+------+
|  id|                name|degree|
+----+--------------------+------+
|7161|      Karluk Airport|     1|
|5653|       Lodja Airport|     1|
|7370|      Breves Airport|     1|
|4125|       Utila Airport|     1|
|8241|São Félix do Xing...|     1|
|7369|Santana do Aragua...|     1|
|6321|    Portland Airport|     1|
|1040|     Kalemie Airport|     1|
|7176|Zachar Bay Seapla...|     1|
|6372| Dalanzadgad Airport|     1|
|9758|Corazon de Jesus ...|     1|
|3968|Massawa Internati...|     1|
```

Рисунок 8 - Результат виконання завдання 3

```
Out[8]: 22
```

Рисунок 9 - Результат виконання

**4.Знайти найкоротший та найдовший маршрут між 2 заданими аеропортами. За довжину рейсу беремо відстань між аеропортами. Необхідно врахувати маршрути з пересадками (не більше 4).**

Для виконання даного завдання було обрано два аеропорта #507 - "London" London Heathrow Airport and 3127 - 'Pokhara' Pokhara Airport та використовуючи motif відфільтровуємо на наступному етапі об’єднуємо в один фрейм, визначаємо список всіх потенційних колонок, розраховуємо

довжину шляху для кожного з варіантів та знаходимо найкоротший (рисунок 10) та найдовший маршрути (рисунок 11).

```
Кількість маршрутів між двома аеропортами з урахуванням максимум 4х пересадок - 20297
Найкоротший маршрут -
Row(a=Row(id='507', Name='London Heathrow Airport', City='London', Country='United Kingdom'), e1=Row(src='507', dst='3093', Airline='VS', Distance
=6727.06133430997), b=Row(id='3093', Name='Indira Gandhi International Airport', City='Delhi', Country='India'), e2=Row(src='3093', dst='3125', Ai
rline='6E', Distance=814.6533497500844), c=Row(id='3125', Name='Tribhuvan International Airport', City='Kathmandu', Country='Nepal'), e3=Row(src
='3125', dst='3127', Airline='YT', Distance=146.32703780342354), d=Row(id='3127', Name='Pokhara Airport', City='Pokhara', Country='Nepal'), e4=Non
e, e=None, total_distance=7688.0417218634775)
```

Рисунок 10 - Найкоротший маршрут

```
Найдовший маршрут -
Row(a=Row(id='507', Name='London Heathrow Airport', City='London', Country='United Kingdom'), e1=Row(src='507', dst='2564', Airline='BA', Distance
=9454.242010778558), b=Row(id='2564', Name='Guarulhos - Governador André Franco Montoro International Airport', City='Sao Paulo', Country='Brazi
l'), e2=Row(src='2564', dst='1701', Airline='TK', Distance=10542.36705283209), c=Row(id='1701', Name='Atatürk International Airport', City='Istanb
ul', Country='Turkey'), e3=Row(src='1701', dst='3125', Airline='TK', Distance=5298.1223324571565), d=Row(id='3125', Name='Tribhuvan International
Airport', City='Kathmandu', Country='Nepal'), e4=Row(src='3125', dst='3127', Airline='YT', Distance=146.32703780342354), e=Row(id='3127', Name='Po
khara Airport', City='Pokhara', Country='Nepal'), total_distance=25441.058433871232)
```

Рисунок 11 - Найдовший маршрут

**5.Знайти авіакомпанію з найбільшою сумою відстаней всіх рейсів**.

Групуємо та використовуємо агреговану функцію sum (результат на рисунку 12)

```
▸ (3) Spark Jobs
▸ total_distance_by_airline: pyspark.sql.dataframe.DataFrame = [airline: string, total_distance: double]
Авіакомпанія з найбільшою загальною відстанню: AA, Відстань: 5430366.439486928 км
```

Рисунок 12 - Результат виконання завдання 5

**6.Виділити великі кластери аеропортів (не менше 5, на основі інформації про рейси). Проаналізувати результати створення цих кластерів.**

Об’єднуємо label до вершин з правильним визначення колонок, наступним кроком знаходимо кількість аеропортів у кожному кластері, сортуємо та отримуємо тільки 5 найбільших і візуалізуємо (рисунок 13

```
Аеропорти в кластері 257698037782 (Label ID):
+----+------------------------------------------------------------+
|id  |Name                                                        |
+----+------------------------------------------------------------+
|6731|Arenal Airport                                              |
|125 |Gander International Airport                                |
|3650|Range Regional Airport                                      |
|3826|Mc Allen Miller International Airport                       |
|3858|Minneapolis-St Paul International/Wold-Chamberlain Airport  |
|5523|Powell River Airport                                        |
|1808|Licenciado Miguel de la Madrid Airport                      |
|2898|F. D. Roosevelt Airport                                     |
|3838|Watertown International Airport                             |
|3949|Santa Barbara Municipal Airport                             |
|4127|Glacier Park International Airport                          |
|5757|Southwest Oregon Regional Airport                           |
|7056|Charlotte County Airport                                    |
|1903|Vilo Acuña International Airport                            |
|1953|Lynden Pindling International Airport                       |
|2888|Eugenio Maria De Hostos Airport                             |
```

Рисунок 13 - Результат виконання завдання 6

```
▸ large_cluster_airports:  pyspark.sql.dataframe.DataFrame = [id: string, Name: s
▸ large_clusters:  pyspark.sql.dataframe.DataFrame = [label: long, count: long]
▸ result:  pyspark.sql.dataframe.DataFrame = [id: string, Name: string ... 3 more
▸ vertices_with_labels:  pyspark.sql.dataframe.DataFrame = [id: string, Name: str

*** WARNING: max output size exceeded, skipping output. ***

                                  |
|4158 |Dong Tac Airport                              |
|6358 |Enshi Airport                                 |
|3939 |Sukhothai Airport                             |
|6008 |Cheongju International Airport                |
|9844 |Anshan Air Base                               |
|6347 |Shijiazhuang Daguocun International Airport   |
|6359 |Nanyang Jiangying Airport                     |
|3377 |Pyongyang Sunan International Airport         |
|6098 |Ugolny Airport                                |
|6357 |Zhanjiang Airport                             |
|6433 |Dandong                                       |
|3930 |Incheon International Airport                 |
|6378 |Zhaotong Airport                              |
|6944 |Jining Qufu Airport                           |
|10941|Arxan Yi'ershi Airport                        |
|3369 |Taiyuan Wusu Airport                          |
|6360 |Xiangyang Liuji Airport                       |
```

Рисунок 14 - Результат виконання завдання 6

**7.Знайти підграфи, з кількістю вузлів не менше 2 зв’язаних між собою, які не мають зв’язків з іншими аеропортами.**

Всі результати виконання даного завдання на скрінах файлів. (рисунок 15 - рисунок 21).

```
+------------+-----+
|   component|count|
+------------+-----+
|          11| 3304|
|          24|    4|
|266287972377|    4|
|300647710744|   10|
|352187318296|    4|
|438086664220|    2|
|523986010153|    2|
+------------+-----+
```

Рисунок 15 - результат виконання 7 завдання

```
Аеропорти в компоненті 11:
+----+--------------------------------+
|id  |name                            |
+----+--------------------------------+
|1512|Falcone-Borsellino Airport      |
|2069|Ha'il Airport                   |
|2136|Kerman Airport                  |
|2162|Tabriz International Airport    |
|2294|Wakkanai Airport                |
|296 |Tozeur Nefta International Airport|
|3414|Point Lay LRRS Airport          |
|3959|Vilnius International Airport   |
|467 |George Best Belfast City Airport |
|5925|Al-Jawf Domestic Airport        |
|6194|Pleiku Airport                  |
|6240|Birdsville Airport              |
|6731|Arenal Airport                  |
|675 |Rzeszów-Jasionka Airport        |
|691 |Gothenburg City Airport         |
|7252|Postville Airport               |
|125 |Gander International Airport    |
```

Рисунок 16 - результат виконання 7 завдання

```
Аеропорти в компоненті 24:
+----+--------------------+
|id  |name                |
+----+--------------------+
|5645|Eros Airport        |
|5642|Ondangwa Airport    |
|6779|Katima Mulilo Airport|
|7634|Rundu Airport       |
+----+--------------------+
```

Рисунок 17 - результат виконання 7 завдання

```
Аеропорти в компоненті 266287972377:
+----+---------------------------------------------+
|id  |name                                         |
+----+---------------------------------------------+
|3726|Boeing Field King County International Airport|
|7083|Orcas Island Airport                         |
|7082|Friday Harbor Airport                        |
|5731|William R Fairchild International Airport    |
+----+---------------------------------------------+
```

Рисунок 18 - результат виконання 7 завдання

```
Аеропорти в компоненті 300647710744:
+----+----------------------+
|id  |name                  |
+----+----------------------+
|2000|Lifou Airport         |
|2002|Maré Airport          |
|5919|Tiga Airport          |
|2004|Ouvéa Airport         |
|5920|Île Art - Waala Airport|
|1999|Koumac Airport        |
|5921|Île des Pins Airport  |
|1998|Koné Airport          |
|2001|Nouméa Magenta Airport |
|2003|Touho Airport         |
+----+----------------------+
```

Рисунок 19 - результат виконання 7 завдання

```
Аеропорти в компоненті 352187318296:
+----+-------------------+
|id  |name               |
+----+-------------------+
|3860|Unalaska Airport   |
|7195|Atka Airport       |
|6134|Akutan Seaplane Base|
|7196|Nikolski Air Station|
+----+-------------------+
```

Рисунок 20 - результат виконання 7 завдання

```
Аеропорти в компоненті 438086664220:
+----+-----------------------------+
|id  |name                         |
+----+-----------------------------+
|6448|Grand Canyon West Airport    |
|6449|Boulder City Municipal Airport|
+----+-----------------------------+

Аеропорти в компоненті 523986010153:
+----+-----------------------------------+
|id  |name                               |
+----+-----------------------------------+
|7309|Charlotte Amalie Harbor Seaplane Base|
|7310|Christiansted Harbor Seaplane Base   |
+----+-----------------------------------+
```

Рисунок 21 - результат виконання 7 завдання

**Висновок:**

На даному комп'ютерному практикумі ми познайомилися та навчилися працювати в ПЗ cloud.databricks.com/editor , створювати граф та працювати з ними під час виконання відповідно поставлених задач. Також будувати шляхи та знаходити найкоротші шляхи для того, щоб дістатися в пункт назначення максимально швидко та максимально з меншою кількістю стиковок.