Лабораторна робота 7 – Рекурентні нейронні мережі LSTM

Завдання: написати програму, що реалізує рекурентну нейронну мережу LSTM для розпізнавання емоційного забарвлення тексту, використати датасет Yelp Review Polarity.

Виконання завдання: використовуючи датасет Yelp Review Polarity засобами мови програмування Python та бібліотеки TensorFlow було створено повноцінну систему машинного навчання для визначення емоційної забарвленості тексту. Проект створено у двох варіантах: з використанням готової «бібліотечної» реалізації LSTM, а також самостійно написаної мережі за допомогою TensorFlow та Keras.

Файл 'main.py' є точкою входу програми, викликає функції для навчання, оцінки та прогнозування двох моделей: бібліотечної LSTM_YelpReviewPolarity_tf.py та «кастомної» Custom_LSTM_YelpReviewPolarity_tf'.py. Також він містить зразки текстів-відгуків для тестування прогнозів.

Обидві реалізації виконують підготовки даних, під час якої зчитуються тренувальний та тестовий набори даних із файлів 'train.csv' та 'test.csv', змінюються мітки (з 1 на 0 – для негативних, з 2 на 1 – для позитивних), використовується 'Tokenizer' для перетворення тексту в послідовності чисел (токенізація) з максимальним розміром словника 'max_words_in_vocab' (20,000 слів), застосовується 'pad_sequences' для вирівнювання довжини відгуків до 'max_reviews_length' (300 слів), вимірюються часові витрати.

Модель, реалізована у файлі 'LSTM_YelpReviewPolarity_tf.py' є послідовною ('Sequential') і складається з:

- 'Embedding': перетворює слова в щільні вектори розмірності 'embedding_dimension' (128);
- двох шарів LSTM (розмірністю 128 та 64 відповідно) з 'Dropout' (0.5) для зменшення перенавчання, які є частиною бібліотеки TensorFlow;
- 'Dense'-шару з 64 нейронами та активацією ReLU;
- вихідного 'Dense'-шару із сигмоїдною функцією активації для бінарної класифікації (0 або 1).

Використовується оптимізатор 'Adam' із швидкістю навчання 'learning_rate' (0.0001) та функція втрат 'binary_crossentropy'.

Файл 'Custom_LSTM_YelpReviewPolarity_tf.py' реалізує власну логіку LSTM-комірки, яка базується на таких принципах:

- має вхідні ворота ('input gate'), забуваючі ворота ('forget gate'), вихідні ворота ('output gate') та комірку пам’яті ('cell state');
- використовує матриці ваг ('W_i', 'U_i', 'b_i' тощо) для обчислень із ініціалізацією 'glorot_uniform';
- повертає вихід ('h') та стани ('h', 'c') для кожного кроку;
- реєструється як звичайний об’єкт у TensorFlow для збереження та завантаження моделі.

Модель складається з:

- 'Embedding': аналогічно до стандартної моделі, розмірність 128;
- двох шарів 'RNN' із самостійно реалізованою коміркою 'lstm_cell' (128 одиниць);
- 'Dense'-шару із 64 нейронами та активацією ReLU, із 'Dropout' (0.5);
- вихідний 'Dense'-шар із сигмоїдною функцією активації;

Використовується оптимізатор 'Adam' із швидкістю навчання 'learning_rate' (0.001 – вища, ніж у бібліотечній моделі). Перед тренуванням виконується функція для очищення тексту: видаляються HTML-теги, URL, пунктуація, цифри та зайві пробіли, текст приводиться до нижнього регістру.

Для обох рішень також задані наступні параметри:

- 'max_words_in_vocab = 20000' – максимальний розмір словника;
- 'max_reviews_length = 300' – максимальна довжина відгуку;
- 'embedding_dimension = 128' – розмірність векторів вкладень.

Тренування обох моделей виконувалось засобами GPU Tesla T4 у середовищі Google Colab протягом 10 епох з 'batch_size' 128, після чого результати були збережені у відповідні keras-файли:

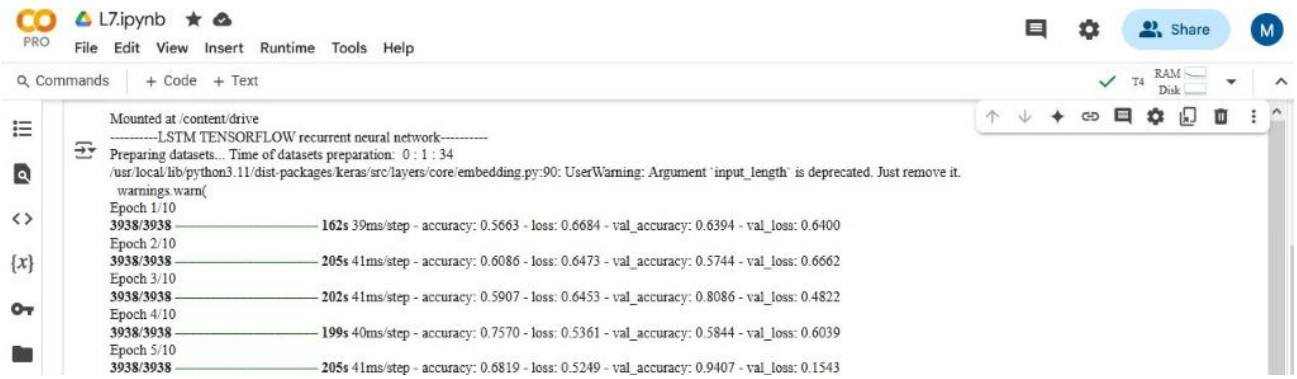

```
Epoch 6/10
3938/3938 ━━━━━━━━━━━━━━━━━━━━ 202s 41ms/step - accuracy: 0.9251 - loss: 0.1931 - val_accuracy: 0.9449 - val_loss: 0.1423
Epoch 7/10
3938/3938 ━━━━━━━━━━━━━━━━━━━━ 198s 40ms/step - accuracy: 0.9348 - loss: 0.1691 - val_accuracy: 0.9459 - val_loss: 0.1405
Epoch 8/10
3938/3938 ━━━━━━━━━━━━━━━━━━━━ 157s 40ms/step - accuracy: 0.9409 - loss: 0.1544 - val_accuracy: 0.9432 - val_loss: 0.1520
Epoch 9/10
3938/3938 ━━━━━━━━━━━━━━━━━━━━ 201s 40ms/step - accuracy: 0.9462 - loss: 0.1432 - val_accuracy: 0.9366 - val_loss: 0.1737
Epoch 10/10
3938/3938 ━━━━━━━━━━━━━━━━━━━━ 205s 41ms/step - accuracy: 0.9504 - loss: 0.1332 - val_accuracy: 0.9389 - val_loss: 0.1732
Time of training:  0 : 32 : 19
The model was saved as  /content/drive/MyDrive/Colab Notebooks/L7/LSTM_YelpReviewPolarity_tf_10_epochs.keras
The history was saved as  /content/drive/MyDrive/Colab Notebooks/L7/LSTM_tf_history.jpg
```

```
L7.ipynb
File Edit View Insert Runtime Tools Help
Commands + Code + Text
----------Custom LSTM TENSORFLOW recurrent neural network----------
Preparing datasets.../usr/local/lib/python3.11/dist-packages/keras/src/layers/core/embedding.py:90: UserWarning: Argument `input_length` is deprecated. Just remove it.
  warnings.warn(
 Time of datasets preparation:  0 : 2 : 22
Epoch 1/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 504s 113ms/step - accuracy: 0.8979 - loss: 0.2521 - val_accuracy: 0.9459 - val_loss: 0.1394
Epoch 2/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 504s 114ms/step - accuracy: 0.9493 - loss: 0.1397 - val_accuracy: 0.9538 - val_loss: 0.1232
Epoch 3/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 502s 114ms/step - accuracy: 0.9624 - loss: 0.1050 - val_accuracy: 0.9532 - val_loss: 0.1335
Epoch 4/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 502s 114ms/step - accuracy: 0.9712 - loss: 0.0821 - val_accuracy: 0.9523 - val_loss: 0.1398
Epoch 5/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 500s 113ms/step - accuracy: 0.9777 - loss: 0.0646 - val_accuracy: 0.9524 - val_loss: 0.1598
Epoch 6/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 501s 113ms/step - accuracy: 0.9833 - loss: 0.0493 - val_accuracy: 0.9519 - val_loss: 0.1913
Epoch 7/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 502s 113ms/step - accuracy: 0.9878 - loss: 0.0382 - val_accuracy: 0.9497 - val_loss: 0.2043
Epoch 8/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 502s 113ms/step - accuracy: 0.9904 - loss: 0.0303 - val_accuracy: 0.9469 - val_loss: 0.2460
Epoch 9/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 505s 114ms/step - accuracy: 0.9917 - loss: 0.0260 - val_accuracy: 0.9492 - val_loss: 0.2616
Epoch 10/10
4375/4375 ━━━━━━━━━━━━━━━━━━━━ 495s 113ms/step - accuracy: 0.9934 - loss: 0.0205 - val_accuracy: 0.9505 - val_loss: 0.2897
Time of training:  1 : 23 : 38
The model was saved as  /content/drive/MyDrive/Colab Notebooks/L7/Custom_LSTM_YelpReviewPolarity_tf_10_epochs.keras
The history was saved as  /content/drive/MyDrive/Colab Notebooks/L7/Custom_LSTM_tf_history.jpg
```

Також отримано графіки зміни точності:

Бібліотечна реалізація (LSTM_tf_history)

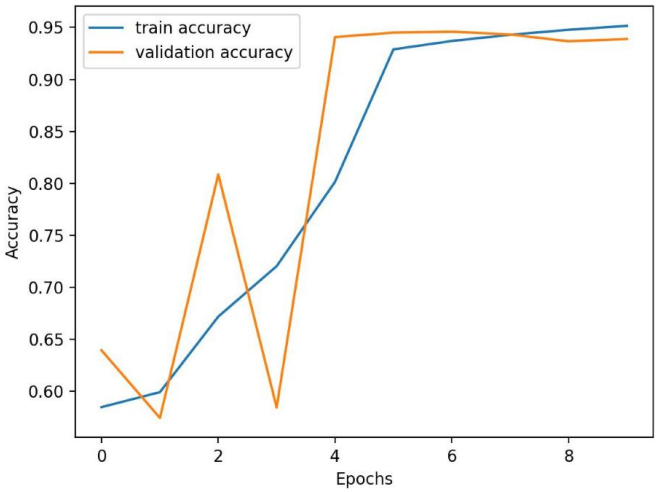

Custom_LSTM_tf_history:

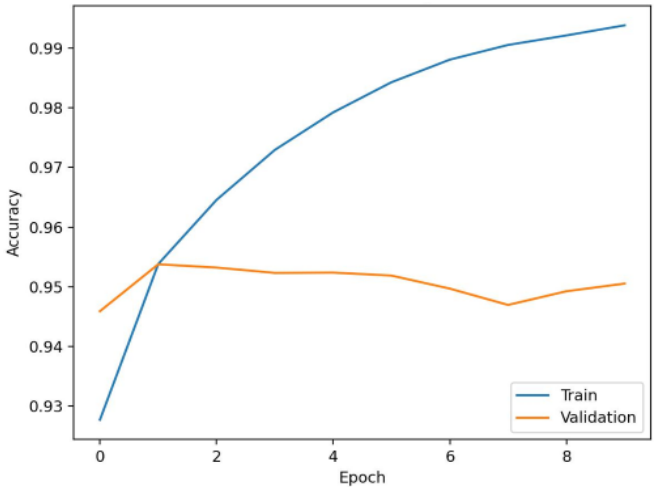

Оцінка точності та визначення емоційного забарвлення виконувались на віртуальній машині під управлінням Windows 11:

```
C:\Windows\system32\cmd.e:
----------LSTM TENSORFLOW recurrent neural network----------
Preparing datasets... Time of datasets preparation:  0 : 1 : 45
Model evaluation... Test accuracy:  0.9296 ; test loss:  0.1997
Preparing datasets... Time of datasets preparation:  0 : 1 : 0
Testing model on sample texts:
This restaurant was amazing! The food was delicious and the service was outstanding. ...
Sentiment:  Positive (confidence: 0.62)
--------------------------------------------------------------------------------
Terrible experience. The staff was rude and the food was cold. ...
Sentiment:  Negative (confidence: 0.58)
--------------------------------------------------------------------------------
```

```
It was okay. Nothing special but nothing terrible either. ...
Sentiment:  Negative (confidence: 0.57)
--------------------------------------------------------------------------------
I've been coming here for years and have never been disappointed. Highly recommend! ...
Sentiment:  Positive (confidence: 0.52)
--------------------------------------------------------------------------------
Wouldn't go back if you paid me. Worst meal I've had in a long time. ...
Sentiment:  Negative (confidence: 0.61)
--------------------------------------------------------------------------------
```

```
C:\Windows\system32\cmd.e

----------Custom LSTM TENSORFLOW recurrent neural network----------
Model evaluation... Preparing datasets... Time of datasets preparation:  0 : 0 : 5
WARNING: All log messages before absl::InitializeLog() is called are written to STDERR
I0000 00:00:1748480222.385711    6064 service.cc:148] XLA service 0x2e8d47a0 initialized for platform Host (th
is does not guarantee that XLA will be used). Devices:
I0000 00:00:1748480222.386011    6064 service.cc:156]   StreamExecutor device (0): Host, Default Version
I0000 00:00:1748480222.807581    6064 device_compiler.h:188] Compiled cluster using XLA!  This line is logged
at most once for the lifetime of the process.
Test accuracy:  0.5000 ; test loss:  0.7741
Preparing datasets... Time of datasets preparation:  0 : 1 : 2
Testing model on sample texts:
This restaurant was amazing! The food was delicious and the service was outstanding. ...
Sentiment:  Positive (confidence: 0.98)
--------------------------------------------------------------------------------
Terrible experience. The staff was rude and the food was cold. ...
Sentiment:  Negative (confidence: 0.94)
--------------------------------------------------------------------------------
It was okay. Nothing special but nothing terrible either. ...
Sentiment:  Negative (confidence: 1.00)
--------------------------------------------------------------------------------
I've been coming here for years and have never been disappointed. Highly recommend! ...
Sentiment:  Positive (confidence: 0.99)
--------------------------------------------------------------------------------
Wouldn't go back if you paid me. Worst meal I've had in a long time. ...
Sentiment:  Negative (confidence: 0.94)
--------------------------------------------------------------------------------
```

На зображеннях видно, що прогнози є однаковими для обох моделей, хоча рівень «впевненості» (ймовірність) у «ручній» реалізації вищий.

Бібліотечне рішення (‘LSTM_YelpReviewPolarity_tf.py’) використовує готову реалізацію двох LSTM-шарів (128 та 64 одиниці), не застосовує додаткове очищення тексту, learning_rate становить 0.0001. «Ручна» модель має власний шар 'lstm_cell' для реалізації LSTM, два RNN-шари з однаковою кількістю одиниць (128), має вищу швидкість навчання ('0.001'), виконує функцію очищення тексту для кращої обробки даних. Вважаємо, що два проаналізованих рішення коректно виконують аналіз тональності тексту з використанням інструментів для глибокого навчання.