Лабораторна робота 8 – Нейронні мережі CNN-bi-LSTM для розпізнавання звуку

Завдання: написати програму, що реалізує нейронну мережу типу CNN-bi-LSTM для розпізнавання мови в текст. Використати датасет LJSpeech.

Виконання завдання: використовуючи датасет LJSpeech засобами мови програмування Python та бібліотеки TensorFlow було створено повноцінну систему машинного навчання для перетворення звукового файлу на текст. Проект створено у двох варіантах: з використанням готової «бібліотечної» реалізації bidirectional LSTM, а також самостійно написаної мережі за допомогою TensorFlow та Keras.

Файл 'main.py' запускає тренування, оцінку та передбачення для двох моделей: 'CNN_bi_LSTM_LJSpeech_tf' та 'Custom_CNN_bi_LSTM_LJSpeech_tf'.

Файл 'CNN_bi_LSTM_LJSpeech_tf.py' містить реалізацію так званої готової або «бібліотечної» моделі для розпізнавання мовлення, з обробкою аудіо у вигляді мел-спектрограм та архітектурою CNN + Bi-LSTM. Підготовка даних включає в себе завантаження набору даних LJSpeech (аудіофайли '.wav' та мета-інформація з 'metadata.csv', яка містить текст, що промовляється в звукових файлах). Аудіо конвертується в мел-спектрограми за допомогою бібліотеки 'librosa' з частотою дискретизації 22050 Гц та розміром 128 мел-коефіцієнтів. Текст транскрипцій перетворюється в числові послідовності за допомогою словника символів ('char_to_num'). Також виконується вирівнювання довжини спектрограм (до 'max_audio_len=1600') шляхом обрізання або доповнення нулями, фільтруються зразки, де довжина текстової послідовності перевищує довжину вхідної послідовності після зменшення розміру (downsampling). Архітектура моделі:

- вхід: мел-спектрограми розміром 'max_audio_len, 128';
- два шари 'Conv1D' (256 фільтрів, ядро 11, активація ReLU) з пулінгом ('MaxPooling1D') для зменшення розмірності;
- нормалізація ('BatchNormalization');
- два двонаправлені шари LSTM ('Bidirectional LSTM', 256 одиниць);
- вихідний шар 'Dense' з активацією 'softmax', який передбачає ймовірності для певної кількості класів (розмір словника + 1 для CTC);
- CTC-втрати: використовується функція 'ctc_loss_fn' для обчислення втрат, яка

враховує змінну довжину послідовностей;

- модель компілюється з оптимізатором Adam та спеціальною функцією втрат 'dummy_ctc_loss' (оскільки справжня втрата обчислюється через 'ctc_loss_fn').

У зв’язку з відсутністю доступу до GPU тренування виконувалось на зменшеному наборі даних, який складається лише з 10 файлів та їхніх 10 «транскрипцій» протягом 10 епох з batch_size = 8 з використанням функції зворотного виклику (callback) 'CTCAccuracyCallback' для обчислення точності після кожної епохи:

```
C:\Windows\system32\cmd.exe
----------CNN-bi-LSTM TENSORFLOW----------
Preparing datasets... Time of datasets preparation:  0 : 0 : 3
Epoch 1/10
1/1 [==============================] - 2s 2s/steploss: 904.0891
Epoch  1 accuracy:  8.33%
2/2 [==============================] - 14s 4s/step - loss: 904.0891
Epoch 2/10
1/1 [==============================] - 0s 440ms/steps: 364.3586
Epoch  2 accuracy:  7.14%
2/2 [==============================] - 6s 3s/step - loss: 364.3586
Epoch 3/10
1/1 [==============================] - 0s 440ms/steps: 335.9307
Epoch  3 accuracy:  0.00%
2/2 [==============================] - 6s 3s/step - loss: 335.9307
Epoch 4/10
1/1 [==============================] - 0s 446ms/steps: 302.5301
Epoch  4 accuracy:  0.00%
2/2 [==============================] - 6s 3s/step - loss: 302.5301
Epoch 5/10
1/1 [==============================] - 0s 438ms/steps: 298.1684
Epoch  5 accuracy:  0.00%
2/2 [==============================] - 6s 3s/step - loss: 298.1684
Epoch 6/10
1/1 [==============================] - 0s 486ms/steps: 288.0956
Epoch  6 accuracy:  6.25%
2/2 [==============================] - 7s 3s/step - loss: 288.0956
Epoch 7/10
1/1 [==============================] - 0s 461ms/steps: 288.6277
Epoch  7 accuracy:  0.00%
2/2 [==============================] - 7s 3s/step - loss: 288.6277
Epoch 8/10
1/1 [==============================] - 0s 460ms/steps: 286.4387
Epoch  8 accuracy:  0.00%
2/2 [==============================] - 7s 3s/step - loss: 286.4387
Epoch 9/10
1/1 [==============================] - 0s 438ms/steps: 285.2509
Epoch  9 accuracy:  4.76%
2/2 [==============================] - 6s 3s/step - loss: 285.2509
Epoch 10/10
1/1 [==============================] - 0s 439ms/steps: 286.3800
Epoch  10 accuracy:  5.88%
2/2 [==============================] - 6s 3s/step - loss: 286.3800
Time of training:  0 : 1 : 11
```

Бачимо некоректні показники точності після кожної епохи тренування, причиною цього, напевно, є використання неповного датасету.

Функція 'eval_and_pred' оцінює модель на 10 випадкових зразках з тестового набору. Передбачення декодуються за допомогою 'ctc_decode' з жадібним алгоритмом, точність обчислюється на рівні символів (Character Accuracy):

```
C:\Windows\system32\cmd.exe
----------CNN-bi-LSTM TENSORFLOW----------
Accuracy:  5.882%
Text:  printing then for our purpose may be considered as the art of making books by means
of movable types
Pred:  n
--------------------------------------------------------------------------------------------
```

```
Text:  in being comparatively modern
Pred:  n
--------------------------------------------------------------------------------
Text:  and it is worth mention in passing that as an example of fine typography
Pred:  n
--------------------------------------------------------------------------------
Text:  printing in the only sense with which we are at present concerned differs from most
if not from all the arts and crafts represented in the exhibition
Pred:  n
--------------------------------------------------------------------------------
Text:  has never been surpassed
Pred:  n
--------------------------------------------------------------------------------
Text:  for although the chinese took impressions from wood blocks engraved in relief for ce
nturies before the woodcutters of the netherlands by a similar process
Pred:  n
--------------------------------------------------------------------------------
Text:  now as all books not primarily intended as picturebooks consist principally of types
 composed to form letterpress
Pred:  n
--------------------------------------------------------------------------------
Text:  the invention of movable metal letters in the middle of the fifteenth century may ju
stly be considered as the invention of the art of printing
Pred:  n
--------------------------------------------------------------------------------
Text:  produced the block books which were the immediate predecessors of the true printed b
ook
Pred:  n
--------------------------------------------------------------------------------
Text:  the earliest book printed with movable types the gutenberg or fortytwo line bible of
 about
Pred:  n
--------------------------------------------------------------------------------
```

Видно, що передбачення також працюють некоректно, а експерименти зі встановленням інших гіперпараметрів не допомогли покращити результати прогнозування. Для дослідження цієї проблеми потрібно тренувати модель на повному дасеті з більшою кількістю епох, наприклад, 50.

Файл 'Custom_CNN_bi_LSTM_LJSpeech_tf.py' реалізує другу модель, яка також використовує набір даних LJSpeech, але з іншою архітектурою та підходом до обробки даних, натхненною DeepSpeech2. Використовується 'tf.data.Dataset' для ефективної обробки інформації, аудіофайли конвертуються в спектрограми за допомогою Short-Time Fourier Transform (STFT) з параметрами: 'frame_length=256', 'frame_step=160', 'fft_length=384'. Спектрограми нормалізуються за допомогою середнього та стандартного відхилення. Текст транскрипцій обробляється через 'StringLookup' для перетворення символів у числа. Дані діляться на тренувальний (90%) та валідаційний (10%) набори. Архітектура моделі:

- вхід: спектрограми розміром '(None, 193, 1)';
- два шари 'Conv2D' (32 та 64 фільтри, ядро '[3, 3]', активація ReLU) з пулінгом ('MaxPooling2D');
- переформування ('Reshape') для подачі в LSTM.
- два двонаправлені шари LSTM ('Bidirectional LSTM', 128 одиниць);
- вихідний шар 'Dense' з активацією 'softmax';

- використовується окрема функція 'CTCLoss', зареєстрована через '@register_keras_serializable';
- модель компілюється з оптимізатором Adam (learning rate = 1e-4).

Тренування виконується з валідацією протягом 10 епох з batch_size = 8:

```
C:\Windows\system32\cmd.exe
----------Custom CNN-bi-LSTM TENSORFLOW----------
Preparing datasets and model... Time:  0 : 0 : 1
Epoch 1/10
2/2 [==============================] - ETA: 0s - loss: 927.6028
Epoch  1 accuracy:  2.68456%
2/2 [==============================] - 16s 5s/step - loss: 927.6028 - val_loss: 820.5073
Epoch 2/10
2/2 [==============================] - ETA: 0s - loss: 781.0289
Epoch  2 accuracy:  2.01342%
2/2 [==============================] - 7s 3s/step - loss: 781.0289 - val_loss: 809.4675
Epoch 3/10
2/2 [==============================] - ETA: 0s - loss: 702.4826
Epoch  3 accuracy:  8.72483%
2/2 [==============================] - 8s 3s/step - loss: 702.4826 - val_loss: 798.3646
Epoch 4/10
2/2 [==============================] - ETA: 0s - loss: 641.4331
Epoch  4 accuracy:  6.71141%
2/2 [==============================] - 8s 3s/step - loss: 641.4331 - val_loss: 787.0762
Epoch 5/10
2/2 [==============================] - ETA: 0s - loss: 593.3651
```

```
Epoch  6 accuracy:  4.69799%
2/2 [==============================] - 8s 3s/step - loss: 557.4305 - val_loss: 767.3480
Epoch 7/10
2/2 [==============================] - ETA: 0s - loss: 528.3964
Epoch  7 accuracy:  5.36913%
2/2 [==============================] - 8s 3s/step - loss: 528.3964 - val_loss: 759.9297
Epoch 8/10
2/2 [==============================] - ETA: 0s - loss: 507.1766
Epoch  8 accuracy:  6.71141%
2/2 [==============================] - 8s 3s/step - loss: 507.1766 - val_loss: 754.6292
Epoch 9/10
2/2 [==============================] - ETA: 0s - loss: 488.3839
Epoch  9 accuracy:  6.71141%
2/2 [==============================] - 8s 3s/step - loss: 488.3839 - val_loss: 751.6992
Epoch 10/10
2/2 [==============================] - ETA: 0s - loss: 475.7674
Epoch  10 accuracy:  5.36913%
2/2 [==============================] - 8s 3s/step - loss: 475.7674 - val_loss: 751.1429
Time of training:  0 : 1 : 26
--------------------------------------------------------------------------------------------
Word Error Rate: 2.0217
```

Порівнюючи результати з попередньою моделлю, можна стверджувати, що дані показники точності є в середньому вищими, проте можуть суттєво змінюватись після кожного нового запуску тренування. Також здійснювалась спроба виконати передбачення для звукових файлів, на яких проводилось тренування моделі:

```
Target    : now as all books not primarily intended as picturebooks consist principally of
types composed to form letterpress
Prediction:  u u v v z z zuuz z z z zuz uu u z z z z z v u z x x x u z z z z z u z r v z u
z z z i u u u z za!aiajajajajajaja
--------------------------------------------------------------------------------------------
Target    : produced the block books which were the immediate predecessors of the true prin
ted book
Prediction:  u e e i u u u z z z x x u u u z z z z z x z v u u u u zzzjajajzjzjzjzjzjzjzjzj
zjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjajajajajajaj
--------------------------------------------------------------------------------------------
Target    : has never been surpassed
Prediction:  z u uu z z z r z ! zazazjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjz
jzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjajajajajajaja
--------------------------------------------------------------------------------------------
Target    : has never been surpassed
Prediction:  z u uu z z z r z ! zazazjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjz
jzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjzjajajajajajaja
--------------------------------------------------------------------------------------------
Target    : for although the chinese took impressions from wood blocks engraved in relief f
or centuries before the woodcutters of the netherlands by a similar process
Prediction:  u u u ue u u e z u z z z z z uuuz z v v h u u uz z u e v v x z z z u u u u u u
uuu z z v x u z uuzu z z z!v
--------------------------------------------------------------------------------------------
```

Видно, що звук перетворюється на текст некоректно: використання повного датасету замість лише 10 файлів, а також тренування моделі протягом більшої кількості епох, наприклад, 50, повинно вирішити дану проблему.

Функція 'evaluate' обчислює точність на рівні символів на валідаційному наборі, а 'speech_to_text' виконує передбачення для випадкового аудіофайлу, виводячи справжній та передбачений текст. Для оцінки якості передбачень використовується метрика Word Error Rate (WER).

```
accuracy: 6.89655%
tf.Tensor(b'LJSpeech-1.1\\wavs\\/LJ001-0002.wav', shape=(), dtype=string)
TRUE TEXT:  in being comparatively modern.
PREDICTED TEXT:   u u u z u u uuuuz
```

Отримана точність є низькою: встановлення причини даної проблеми (помилки в реалізації моделі, неправильна обробка звукових та / або текстових даних, малий обсяг оброблюваної інформації) потребує доступ до значно більших обчислювальних ресурсів.

Також генерується графік зі спектрограмою та аудіосигналом, який зберігається у файл 'Spectrogram_and_wav.jpg':

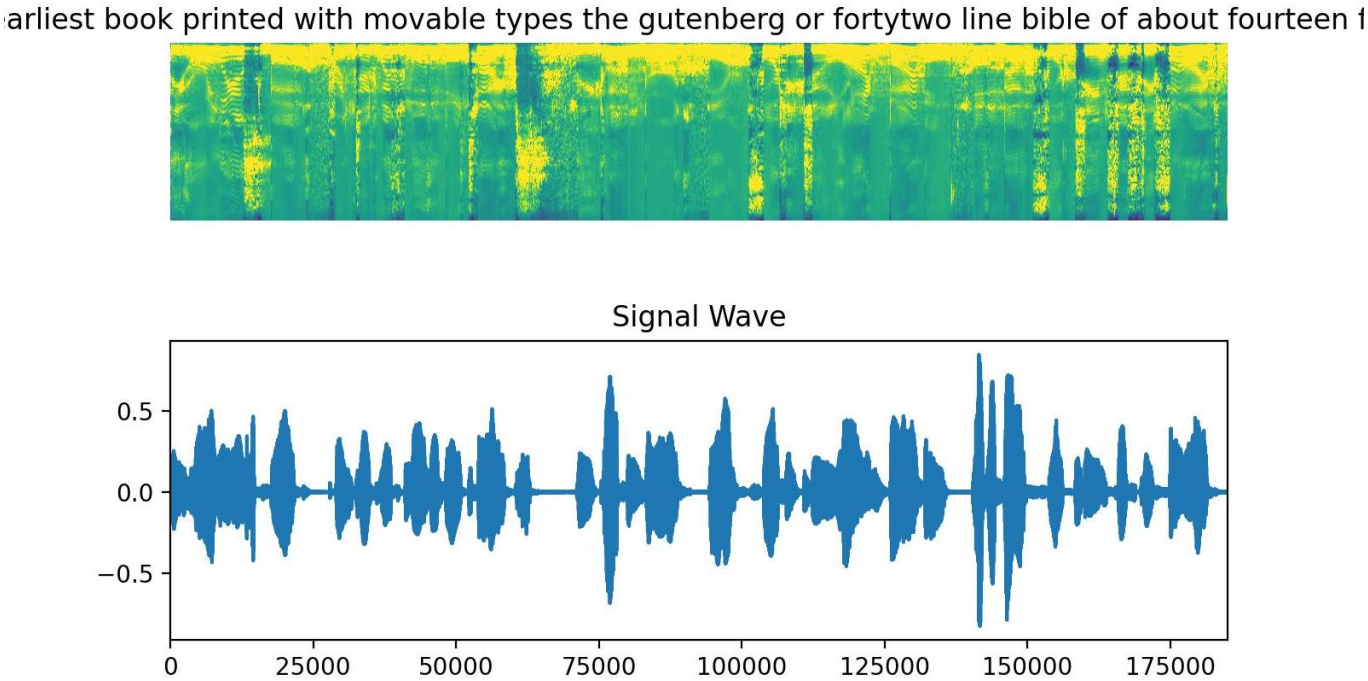

Отже, код реалізує дві моделі для автоматичного розпізнавання мовлення на основі набору даних LJSpeech:

1. Модель 'CNN_bi_LSTM_LJSpeech_tf':

- використовує мел-спектрограми та просту архітектуру CNN + Bi-LSTM;
- тренується без валідаційного набору, що є недоліком;

- оцінюється через точність на рівні символів.

2. Модель 'Custom_CNN_bi_LSTM_LJSpeech_tf':

- використовує STFT-спектрограми та спрощену версію DeepSpeech2;
- має окремий валідаційний набір та оцінку через WER.
- більш сучасний підхід до обробки даних через 'tf.data.Dataset'.

Після належного тренування на повному датасеті протягом більшої кількості епох та, можливо, зі зміненими значеннями деяких гіперпараметрів обидві моделі можуть стати цілком коректними для базового розпізнавання мовлення. Друга модель є більш сучасною та гнучкою завдяки валідаційному набору та WER.